

数据中台数据采集逻辑风险点评审

增加 kucoin bitget kline funding数据

数据准确性验证

coinglass （数据源是否正确）与 binance 的数据源的验证

Tip：

- 1. kline 为例：数据源验证，1min 聚合其他的internal 数据（可以每周，验证过的数据不需要重复验证）
- 2. Coinglass 数据与单个数据源的 binance 数据源的验证对比

数据采集与清洗流程 — 评审说明

文档状态：REVIEW

用途：供内部/外部评审 数据准确性、时间连贯性、规则可行性 与 遗漏点；与运维细节分离，聚焦「数据从哪来、如何落库、如何进 clean、如何质检」。

实现入口：`app/services/tasks/*`（采集）、`app/services/tasks/dqc_tasks.py`（DQC）、`app/services/celery_beat_kline_dqc_minimal.py`（DQC 调度）。

1. 分层与读数约定

层级	职责	下游是否
Raw	保留上游口径、可追溯；多通道（WS / REST）可并行写同一表，靠唯一键去重	否（规范上策略/因子统一不直连 ra
Clean / Curated	DQC 校验或过滤后的统一读源；带 quality_flag、repair_tag 等	是

当前核心 raw 与对应 clean（与本项目 DQC 一致）：

Raw表	
kline_data_future_raw	kline_data_future
kline_data_spot_raw	kline_data_spot
binance_usdm_funding_rate_raw	binance_usdm_funding_rate_clean
coinglass_aggregated_taker_buy_sell_volume_raw	coinglass_aggregated_taker_buy_sell_volume_clean
coinglass_global_long_short_account_ratio_raw	coinglass_global_long_short_account_ratio_clean
coinglass_open_interest_raw	coinglass_open_interest_clean

补充: premium_1m / premium_15m 当前作为 binance_usdm_funding_rate_raw 与 binance_usdm_funding_rate_clean 的逻辑子数据集 (通过 funding_rate_interval=60/900 区分), 纳入 DQC extra_* 链路。

质量追踪: dqc_runs、dqc_issues (问题类型如 TAIL_LAG、RULE_VIOLATION、GAP、STALE_SOURCE 等)。

更细的字段语义见 data_platform_standards.md。

2. 采集（爬取）流程总览

2.1 K 线（Future / Spot）

目标表: kline_data_future_raw、kline_data_spot_raw

通道（可并存）：

WebSocket（主推荐）

- Future: run_binance_future_kline_ws.py → Binance USDM 推送。
- Spot: run_binance_spot_kline_ws.py → Binance Spot 推送。
- 语义：一般在 K 线完结（收盘）后写库，业务时间 timestamp = Binance open_time (ms)。
- 与 REST 关系：同表、同唯一键 (symbol, interval, timestamp)，重复则 upsert/去重。

Celery + REST 增量（可选）

- Future: kline.ingest_binance_kline_periodic (/fapi/v1/klines)。
- Spot: kline.ingest_binance_spot_kline_periodic (/api/v3/klines)。

作用： 定时补增量；可与 WS 同时运行，用于 WS 故障兜底或长周期补洞。

历史回补 / 修洞

与定时 **同一任务**，通过 `from_date` / `to_date`、`max_pages` 等参数控制；大窗可多轮 `run_*_kline_periodic_async`。

1m 专项： `kline_gap_fill` (Future)、`spot_kline_gap_fill` (Spot)：按 LAG 发现内部缺段与尾部，REST 分页补；对 HTTP **451**、连接类错误可做 **跳过当前 gap** 以免全任务中断（仍可能造成局部空洞，需依赖后续轮次或人工）。

配置集中： `app/config/kline_common_config.py`（默认币种、周期、请求 limit、重试策略等）。

部署索引： `RAW_TABLES_SERVER_DEPLOYMENT.md`、`BACKFILL_OPERATIONS.md`、`WEBSOCKET_KLINE_DEPLOYMENT.md`。

2.2 资金费率 (Binance USDM)

目标表： `binance_usdm_funding_rate_raw`

通道： 仅 **Celery**，任务 `usdm.ingest_funding_rate_raw`。

数据源： GET [https://fapi.binance.com/fapi/v1/fundingRate`](https://fapi.binance.com/fapi/v1/fundingRate)（分页：``startTime` 递推）。

粒度： 每行 `(symbol, funding_time)`；结算周期通常为 **8h**（具体以上游为准）。

异常处理： symbol 级 `try/except`，单 symbol 失败会记录到任务 summary 的 `error` 并继续其它 symbol；`persist_http_retry=true` 时对限流/超时使用长重试策略。

风险： 网络/代理不可用可能出现 `ConnectError`、超时或特定出口下的 HTTP 异常（如 **451**），导致 **raw 停更**；clean 依赖 raw，会连锁滞后。

2.2.1 Premium (1m / 15m)

目标表： 与 funding 共用 `binance_usdm_funding_rate_raw`（clean 侧为 `binance_usdm_funding_rate_clean`）

通道： Celery 任务 `usdm.ingest_premium_index_1m_raw`、`usdm.ingest_premium_index_15m_raw`。

语义： 将 Binance premium/mark price K 线按 `funding_time` 入同表，用 `funding_rate_interval=60/900` 区分 `premium_1m` / `premium_15m` 与常规 funding 事件。

与 funding 的边界： settled funding 仍以 `usdm.ingest_funding_rate_raw` 为准；premium 任务用于补充高频 premium/mark price 轨迹。

异常处理： 复用 Binance REST 重试与 upsert 去重逻辑；DQC 在 `extra_tail_sync_and_lag_check`、`extra_quick_validate`、

`source_staleness_alert` 中按 `premium_1m` / `premium_15m` 单独评估。

统一口径声明（评审必读）

Funding 与 Premium 最终都入同一对表：`binance_usdm_funding_rate_raw` / `binance_usdm_funding_rate_clean`。

internal 语义通过 `funding_rate_interval` 分桶区分：`premium_1m`（60）、`premium_15m`（900）、以及真实 funding 结算点位（`1h/2h/...`，通常不为 60/900）。因此 DQC、指标计算与下游消费必须按 `funding_rate_interval` 分桶，禁止混读。

2.3 Coinglass（三张表，当前重点周期 1m / 15m / 1h）

目标表：

`coinglass_aggregated_taker_buy_sell_volume_raw`

`coinglass_global_long_short_account_ratio_raw`

`coinglass_open_interest_raw`

通道：各队列 **Celery** 任务（incremental backfill），Beat 约 **10 分钟** 一级调度。

语义：按 `interval` 拉取聚合时间序列；当前默认 ingest 周期为 `1m`、`15m`、`1h`（可通过配置覆盖）；业务时间列为 `ratio_time` 或 `oi_time`（ms）。

增量：任务内部基于表内最大时间与 `max_span_hours_per_run` 等控制每轮窗口；**无新 bar 时** `total_inserted=0` / `caught_up` 属正常。

异常处理：

`retry_http=true` 时对 Coinglass 限流/临时错误进行退避重试；

遇到 `Invalid time range: earliest allowed start_time ...` 会自动夹紧窗口并重试一轮；

默认 `stop_on_symbol_error=false`，即单 symbol 错误不阻断整轮。

配置集中：`app/config/raw_sources_common_config.py`。

3. Raw 层算法要点（准确性相关）

3.1 去重与幂等

- **K 线：**唯一键 `(symbol, interval, timestamp)`；多写源冲突时以 **upsert / ON DUPLICATE KEY UPDATE** 合并，以最后一次写入覆盖同键字段（需评审：是否接受「后写覆盖先写」策略）。
- **Funding：**`(symbol, funding_time)`。
- **Coinglass：**各表 `(symbol, interval, ratio_time|oi_time)`。

3.2 K 线业务时间

- `timestamp` = K 线 开盘时间 (ms) , 与 Binance API 一致。
- **WS 仅收盘写**: 未收盘的当前 K 不会在 raw 出现, 因此「最新 raw 时间」相对墙钟 **落后最多约一个周期** 是预期行为。

3.3 HTTP / 代理

- Binance REST 侧普遍支持 `BINANCE_HTTP_PROXY` 等; 代理异常会导致 **采集停更**, 与 DQC `STALE_SOURCE` 联动。
- WS 与 REST 出口策略不一致时, 可能出现 **一侧正常一侧断** 的分裂状态。

4. 清洗 (DQC) 流程与算法

实现主文件: `app/services/tasks/dqc_tasks.py`

调度: `app/services/celery_beat_kline_dqc_minimal.py` (摘要见下节)。

4.1 K 线: Raw → Curated (`kline_data_*`)

任务 `dqc.kline_tail_sync_and_lag_check` (每 10 分钟)

取 raw / curated 全局 `MAX(timestamp)`。

Tail同步 SQL逻辑要点: 仅插入 raw 中满足 `timestamp > curated_max` 的行, 且通过 **OHLC 一致性过滤** (转为 `DECIMAL` 后):

`high >= low`, `high >= open/close`, `low <= open/close`, `volume >= 0`。

含义: raw 中 **OHLC 异常或 volume 为负** 的尾部数据 **不会进入 clean**, 直至 raw 被修复或 DQC 其他路径处理。

若 `raw_max - clean_max` 大于 `lag_threshold_ms` (默认 60s), 记 **TAIL_LAG** 类问题 (具体落库见 `dqc_issues`)。

任务 `dqc.kline_quick_check_and_patch` (每 10 分钟, 默认回看 6h)

默认 interval: `1m`, `15m`, `1h`。

检查:

主键重复;

时间轴 **LAG缺口** (按周期步长推算缺失根数);

OHLC 规则 (与 tail 同步类似)。

动作: 可自动去重、小缺口触发定点回补 (与 `sync_curated` 等参数配合); 未解决写入 `dqc_issues`。

任务 `dqc.kline_hourly_reconcile` (每小时)

更长回看（默认 3 天）、更多周期；聚合问题并推进修复状态机（REPAIRING / FIXED / FAILED）。

任务 `dqc.kline_daily_full_dqc`（每天 02:30）

更广窗口（默认 30 天）体检与汇总。

4.2 Funding / Premium / Coinglass: Raw → Clean

任务 `dqc.extra_tail_sync_and_lag_check`（每小时）

将 业务时间大于 clean 当前最大值的 raw 行 INSERT ... ON DUPLICATE 到对应 *_clean。

Funding: 按 `funding_time`；字段含 `funding_rate`、`mark_price`、`funding_rate_interval`。

Premium (1m/15m)： 同样按 `funding_time` 同步，但通过 `funding_rate_interval=60/900` 与 settled funding 区分（对应数据集：`premium_1m`、`premium_15m`）。

Coinglass: OI 按 `oi_time`；另两张按 `ratio_time`（当前重点周期 `1m`、`15m`、`1h`）。

默认 lag 告警阈值： `lag_threshold_ms = 3600000`（1h）（与 staleness 阈值不同，评审时注意区分）。

任务 `dqc.extra_quick_validate`（每小时）

规则校验 (raw)：

funding: `mark_price >= 0`；

premium_1m / premium_15m: `mark_price >= 0`（与 funding 同表按 `funding_rate_interval` 分桶校验）；

OI: 四价非负；

L/S: `global_account_long_short_ratio > 0`；

Taker B/S: 买卖量与 ratio 非负。

连贯性：

funding: 按 固定 8h (28800000 ms) 用 LAG 估计「缺几次结算」；若个别 symbol 非 8h 周期，此规则可能 误报或漏报。

premium_1m / premium_15m: 分别按 1m / 15m 步长检查连续性缺口。

Coinglass: 按 (symbol, interval) 用 interval 步长 做 LAG gap 统计（重点覆盖 `1m`、`15m`、`1h`）。

任务 `dqc.source_staleness_alert`（每 10 分钟）

看 raw 表 MAX(业务时间) 与当前时间差；超阈值写 STALE_SOURCE。

默认阈值： funding 10h； premium_1m 15m； premium_15m 45m； Coinglass 当前按数据集统一 2h 阈值监控（非按 interval 分桶）。

详细任务清单与手动触发示例见 DAILY_DQC_AUTOMATION.md。

4.3 DQC 调度一览（当前 Beat）

周期	任务
每 10 分钟	kline_tail_sync_and_lag_check、 kline_quick_check_and
每 1 小时	kline_hourly_reconcile、 extra_tail_sync_and_lag_check、
每日 02:30	kline_daily_full_dqc

5. 连贯性与「是否在涨」的判读建议（给评审）

1. K 线 clean - 允许 略滞后于 raw（tail 同步周期 + 过滤条件）；若长期差 多个周期，优先查 DQC 日志与 dqc_issues。
- 1m 最新时间落后墙钟 约 1~2 分钟 常见（收盘写入 + 同步间隔）。
2. Funding raw
- 不是每分钟增长；约 每 8h / symbol 级事件。应看 MAX(funding_time) 是否随结算推进。

◦ clean 应随 extra_tail_sync 推进；若 raw 新而 clean 旧，多为 同步未跑或失败。
3. Coinglass raw
- 当前重点周期为 1m / 15m / 1h； total_inserted=0 可能为 已追上或 API 无新点。

◦ clean 落后 raw 1~2 个 bar 时需结合 extra_tail_sync_and_lag_check（小时级运行）是否执行成功。

6. 可行性评估与已知遗漏 / 风险（评审清单）

以下条目建议在评审会上 明确接受或排期改进：

#	主题	
R1	多源写 K 线	WS与 REST 同键覆盖顺序是否满足研究口径；机
R2	Tail 同步过滤	未通过 OHLC/volume 检查的 raw 永不自动进 c
R3	Funding 8h 假设	extra_quick_validate 中 gap 用 28800000ms；
R4	代理与地域	451 / TLS / ConnectError 导致 raw 停更；无自i
R5	Coinglass 语义	聚合多交易所、比例是否需 /100 等 因子侧映射
R6	DQC 与人工	IGNORED、回补脚本、与 dqc_issues 闭环是否
R7	其他 raw 表	如 binance_usdm_open_interest_raw、curat 路内；若下游使用，需单独声明是否纳入同一套
R8	时钟与 TZ	全链路以 UTC ms 为准；展示与报表需统一时区
R9	Premium 混表口径	premium_1m/15m 与 funding 共用 binance_u 桶，易发生指标混读。
R10	Coinglass 多周期覆盖	当前已并行 1m/15m/1h；若监控或验收仅覆盖:

7. 相关文档索引

文档	
DAILY_DQC_AUTOMATION.md	DQC 任务定义、阈值、Cron/C
RAW_TABLES_SERVER_DEPLOYMENT.md	六张 raw 表采集进程与脚本
BACKFILL_OPERATIONS.md	回补与 Celery 调用约定
data_platform_standards.md	表结构、时间语义、命名
WEBSOCKET_KLINE_DEPLOYMENT.md	WS 部署与运维
FACTOR_DATA_API_SPEC.md	若因子/API 消费 clean 层，可.

8. 修订记录

日期	说明
2026/4/10	初版：汇总采集 + DQC 清洗逻辑与评审风险项
2026/4/15	增补：内部风险评审执行模板（议程 / 台账 / 验收）
2026/4/15	同步：Funding/Premium 同表分桶口径、Coinglass 1m/15m/1h 覆盖、DQC

9. 内部数据风险评审结论（基于当前代码实现）

范围：实时采集（Kline WS/REST、Funding REST、Coinglass REST）+ 历史回补 + DQC 清洗入库。

9.1 结论摘要（供评审会开场）

- 1. 链路具备“采集 -> 回补 -> DQC -> clean”基本闭环，且 `dqc_runs` / `dqc_issues` 可追溯。
- 2. 异常处理总体策略为“符号级容错 + 任务级记账”：单 symbol 失败通常不拖垮整轮，但会进入 `error` 或 DQC issue。
- 3. 主要残余风险集中在：多源同键覆盖顺序、gap 跳过后的二次补偿、Funding gap 固定 8h 假设、无自动切线路。
- 4. 当前状态适合继续运行，但建议按 P0/P1 项做增强后再作为“对外稳定口径”。

9.2 分层风险与异常处理（已落到代码行为）

A) 采集层（实时）

主题	当前代码行为（含异常处理）	残余风险	
Kline WS/ REST 并发 写同键	raw 侧按唯一键 (symbol, interval, timestamp) upsert; REST 拉取在 persist_http_retry=false 时对 429/418/超时指数退避，418 连 续后会 hard_rate_limited 并跳过 当前 symbol 本轮; persist_http_retry=true 时走长 重试 (await_httpx_get_with_retries)。	同键字段“后写覆盖先 写”，来源优先级未固化 为显式规则。	P0 ：需决定是
Funding 分 页边界	每 symbol 先查最新 funding_time，起点 max(from_date, latest+1ms)， 到 now_ms 分页拉取；symbol 级异常 except 后写入 summary["symbols"][error]，继 续其他 symbol。	单 symbol 持续报错时不 会阻断全任务，但可能长 期漏该 symbol。	P1 ：需对连续
Coinglass 增量窗口	每轮每 symbol 仅推进 max_span_hours_per_run; start_ms >= end_ms 标记 skipped=caught_up；支持 retry_http 开关（重试上限可到 80）。	max_span_hours_per_ru n 偏小会出现“长期追不 齐但每轮看似成功”。	P1 ：需按数据
HTTP/上游 异常	Coinglass 返回 invalid time range 时会解析 earliest allowed start 并自动夹紧窗口重试一次； HTTP 可重试错误（429/418/503/ timeout/rate limit）退避重试； 非可重试错误写入 error。	无线路自动切换；error 依 赖任务日志/上层巡检感 知。	P0 ：网络故障

B) 回补层（历史 + 缺口）

主题	当前代码行为（含异常处理）	残余风险	
gap 发现与多轮补齐	run_1m_gap_fill_until_stall 多轮执行，连续 max_stall_rounds 无插入才退出； raw_with_backfill_loops 对 kline/coinglass 也有 stall 防误停逻辑。	stall 判定依赖“插入量”，对“重复 upsert 无新增”场景敏感。	P1：建议增加“业务时间推进”车
451/连接异常处理	在 kline_gap_fill/spot_kline_gap_fill 中，HTTP 451 或 ConnectError/Timeout 会“跳过当前 gap”并继续后续 gap，避免整轮中断。	被跳过的 gap 可能形成长期空洞，依赖后续轮次或人工再补。	P0：需增加“被跳过 gap 清单”排
Coinglass until_caught_up 循环	当全 symbol skipped=caught_up 时停止；否则按无新增插入计数，达到 RAW_BACKFILL_COINGLASS_MAX_STALL_ROUNDS 停止并返回 stalled_no_insert。	“无新增”不等于“无缺口”，仍需结合时间轴检查。	P1：会后必须跑 gap/新鲜度验证
回补与实时并发	设计上允许并行，依赖唯一键 upsert 幂等；部分脚本提供“先回补后拉起常驻”标准流程。	高并发下数据库与 API 限流压力升高。	P2：建议设定维护窗口与并发上限

C) 清洗层 (DQC)

主题	当前代码行为（含异常处理）	残余风险	
tail sync 乱序风险	Kline tail 同步按 timestamp > curated_max + OHLC/ volume 规则过滤写 clean；dataset 级失败会 logger.exception，run 状态标记 FAILED，并统计 failed_count。	若存在乱序晚到且 timestamp <= curated_max，不会被 tail 任务补入。	P0 ：需确认是否由 q
OHLC 过滤副作用	不合法 OHLC/负 volume 直接拦截，不入 clean；lag 超阈值落 TAIL_LAG。	“正确拦截”与“业务漏数”之间缺少分级告警策略。	P1 ：建议区分阻断级
DQC 状态闭环	dqc_runs 记录 run 结果；dqc_issues 记录 TAIL_LAG/ GAP/RULE_VIOLATION/ STALE_SOURCE，任务异常会将 run 置 FAILED。	issue 状态机（OPEN/ REPAIRING/FIXED/ FAILED/IGNORED）依赖任务与人工共同维护，自动闭环强度有限。	P1 ：需补“超期未闭
Funding 8h 假设	extra_quick_validate 中 funding gap 仍存在 28800000ms（8h）口径；同时代码注释说明上游可能 1h/4h/8h。	对非 8h 合约可能误报/漏报。	P0 ：改为按 symbol

D) 配置与发布层

主题	当前代码行为（含异常处理）	残余风险	
配置漂移	关键参数集中在 kline_common_config.py 、 raw_sources_common_config.py ，但运行时可被任务参数覆盖。	“代码默认值 vs 线上参数”偏差可能导致评审结论失真。	P1 ：评审会需附线上实参快照。
队列映射错误	Beat 中已显式绑定队列（dqc、funding、coinglass_*）；若 worker 未消费对应队列会出现“有调度无执行”。	该问题在日志层可见，但缺统一健康面板。	P0 ：必须有按队列的任务积压监控
同窗发布一致性	文档要求 DQC 与 raw 同环境同窗口发布；任务失败会体现在 dqc_runs 状态。	若实际未同窗发布，短期 clean lag 会升高。	P1 ：发布流程需强校验“采集与D

9.3 评审判定（可直接对外）

风险ID	判定	依据（当前实现）	
R1 多源同键覆盖	未完全收敛	upsert 可幂等但未固化来源优先级	整改后
R2 gap 跳过补偿	未完全收敛	451/连接异常会跳过当前 gap	整改后
R3 Funding 周期校验	未通过	gap 校验仍固定 8h	必须整
R4 网络线路韧性	未通过	无自动切线，主要靠重试与人工	必须整
R5 DQC 闭环可观测性	基本通过	run/issue 有记录	带条件
R9 Premium 混表口径	未完全收敛	funding 与 premium 共表，依赖 funding_rate_interval 分桶消费	整改后
R10 Coinglass 多周期覆盖	未完全收敛	已并行 1m/15m/1h，但监控与验收可能只看单周期	整改后

9.4 本次建议整改项（直接执行）

优先级	改造项	
P0	Funding gap 校验改为按 symbol funding_rate_interval	消除 8h 误报/漏报
P0	落地 “被跳过 gap 清单” 表 + 告警	避免 451/连接异常形成隐性空洞
P0	增加按队列 worker 消费与积压监控	避免 “beat 正常但 worker 未消
P0	统一下游按 funding_rate_interval 分桶读 funding/premium	避免混表口径误读
P1	明确 Kline 同键来源优先级策略（WS/ REST）	固化一致性口径
P1	增加 dqc_issues 超期未闭环告警	提高问题闭环率
P1	评审记录附线上实参快照（各 beat/任务）	防止配置漂移造成误判
P1	Coinglass 验收报表按 interval in (1m,15m,1h) 分维度出具	防止单周期监控漏报